1. Phân rã giá trị kỳ dị SVD

1.1. Định lý

Mọi ma trận thực A cỡ m×n đều viết được thành

$$A = U\Sigma V^T$$

U và V là các ma trận trực giao ($U^TU = I$, $V^TV = I$), còn Σ là ma trận chéo. Ba ma trận này có vai trò như sau.

1.2. Ý nghĩa của U Σ và V

Thành phần	Kích thước	Là gì	Vai trò
V	n×n	Các cột v_i là vector kỳ dị phải	Cơ sở trực chuẩn của không gian đầu vào (không gian hàng của A)
Σ	m×n	Chỉ có đường chéo $\sigma_1 \geq \sigma_2 \geq \ldots \geq 0$	Các giá trị kỳ dị: hệ số co giãn theo từng hướng
U	m×m	Các cột u_i là vector kỳ dị trái	Cơ sở trực chuẩn của không gian đầu ra (không gian cột của A)

Hạng của A bằng số $\sigma_i > 0$.

Hai ma trận U và V ghép cặp với nhau qua Σ:

$$Av_i = \sigma_i u_i \quad và \quad A^T u_i = \sigma_i v_i$$

Nghĩa là A biến hướng v_i thành hướng u_i, kéo dãn σ_i lần. A^T làm chiều ngược lại.

1.3. Diễn giải hình học

$Ax = U(\Sigma(V^Tx))$ gồm ba bước:

V^T quay các hướng v_i về trùng với các trục tọa độ.

Σ kéo dãn trục thứ i theo hệ số σ_i.

U quay kết quả về các hướng u_i.

Do phép quay giữ nguyên độ dài, đường tròn đơn vị biến thành một ellipse có bán trục σ_i theo hướng u_i. Vì vậy $\sigma_1 = \max\|Ax\|$ (với $\|x\| = 1$), đạt tại $x = v_1$. Nếu $\sigma_i = 0$ thì một chiều bị mất.

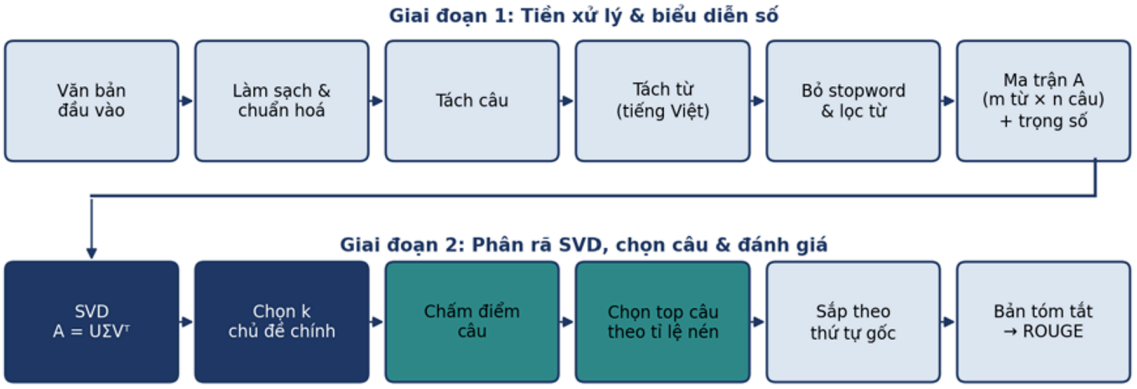
2. Ứng dụng SVD để xác định câu quan trọng

2.1. Ý tưởng

Một văn bản thường bàn về vài chủ đề, mỗi chủ đề được thể hiện bằng một tổ hợp từ lặp lại ở nhiều câu. Nếu biểu diễn văn bản thành ma trận từ–câu rồi phân rã SVD thì: mỗi vector kỳ dị biểu diễn một chủ đề; giá trị kỳ dị cho biết chủ đề đó quan trọng đến đâu; các thành phần của

vector kỳ dị phải cho biết câu nào gắn với chủ đề. Câu quan trọng là câu đóng góp mạnh vào các chủ đề quan trọng

2.2. Luồng xử lý dữ liệu tổng thể



2.3. Xây dựng ma trận A

Kích thước m × n được xác định như sau:

n = số câu của văn bản sau bước tách câu (mỗi câu là một cột).

m = số từ trong từ vựng (mỗi từ là một hàng) – tức số từ phân biệt còn lại sau tiền xử lý

Có thể lựa chọn từ vựng theo các cách sau:

Chiến lược	Cách làm	Nhận xét
Toàn bộ từ phân biệt	Giữ mọi từ còn lại sau bỏ stopword	Đơn giản, chuẩn của công trình gốc; m thường ≥ n
Lọc theo tần suất tài liệu	Giữ từ có df ≥ 2 (xuất hiện ≥ 2 câu)	Từ chỉ ở một câu không tạo liên kết giữa các câu; giảm nhiễu và giảm m
Lọc theo từ loại	Chỉ giữ danh từ, động từ, tính từ (POS)	Tập trung từ mang nội dung; cần bộ gán nhãn
Giới hạn kích thước	Chọn top-m từ theo tf hoặc tf-idf	Hữu ích khi văn bản/tập rất lớn
Từ vựng ngoài	Dựng từ vựng và IDF từ kho ngữ liệu lớn	Cho IDF ổn định hơn khi chỉ có một văn bản

Các cách xây dựng ma trận A

	Cách 1: Trọng số từ	Cách 2: Word2Vec
Ý tưởng	Mỗi hàng là một từ; a_{ij} là độ "nặng" của từ i trong câu j	Mỗi hàng là một chiều nhúng; mỗi câu là trung bình vector các từ trong câu
Kích thước	m × n (m = số từ, n = số câu)	100 × n (PhoW2V 100 chiều)

	Cách 1: Trọng số từ	Cách 2: Word2Vec
Cách tính a□	Các công thức được trình bày trong bảng trọng số từ bên dưới.	1. Chuẩn hóa từ (chữ thường, NFC, giữ dấu _) 2. Tra vector từ trong PhoW2V 3. Từ không có sẵn: tách thành các từ nhỏ rồi lấy trung bình (bài_giảng = bài + giảng) 4. Trung bình vector các từ, tính theo số lần xuất hiện 5. Xếp các vector câu thành cột của A^E
Giá trị lấy từ	Đếm trong văn bản	Vector huấn luyện sẵn
Dấu của phần tử	≥ 0	Có thể âm
Giải thích chủ đề (cột của U)	Xem được trực tiếp: phần tử lớn của u_i chỉ ra từ khóa của chủ đề	Không xem trực tiếp được: phải tìm thêm từ có vector gần hướng u_i mới giải thích được
Gần nghĩa	Gián tiếp, qua đồng xuất hiện và SVD	Có phản ánh qua vector nhúng
Ưu điểm	Dễ đọc, dễ kiểm tra	Nắm được quan hệ gần nghĩa
Hạn chế	Không biết từ gần nghĩa, mất thứ tự từ	Mất thứ tự từ, khó giải thích chủ đề
Bước chung sau đó	(Tùy chọn) chuẩn hóa L2 từng cột: ã□ = a□ / ‖a□‖₂ → SVD → chấm điểm câu	(Tùy chọn) chuẩn hóa L2 từng cột: ã□ = a□ / ‖a□‖₂ → SVD → chấm điểm câu

Các công thức trọng số từ

Trọng số	Công thức $a_{i□}$	Ghi nhớ
TF	$f_{i□}$	Đếm số lần từ xuất hiện
Binary	1 nếu có, 0 nếu không	Chỉ xét có hay không
Log-TF	$\log(1 + f_{i□})$	Giảm ảnh hưởng của từ lặp nhiều
TF-IDF	$f_{i□} \cdot \log(n / df_i)$	Hạ trọng số từ có mặt ở quá nhiều câu
Log-entropy	$\log(1 + f_{i□}) \cdot g_i$	Từ rải đều các câu thì g_i nhỏ

Lưu ý: khi so sánh các cách, nên cùng chuẩn hóa L2, và không so trực tiếp điểm thô giữa TF-IDF và Word2Vec vì thang đo khác nhau.

2.4. Các cách lựa chọn số thành phần k

k là số chiều kỳ dị giữ lại để đánh giá câu, c là số câu cần chọn, còn $r = rank(A)$. Các giá trị kỳ dị được sắp xếp: $\sigma_1 \geq \cdots \geq \sigma_r > 0$.

Cách chọn k	Quy tắc	Ý nghĩa và lưu ý
Theo số câu cần chọn	$k = c \leq r$.	Dùng trong Gong & Liu: mỗi chiều chọn một câu. Khi cần nhiều câu, phải sử dụng thêm các chiều yếu hơn.
Theo ngưỡng tương đối	$k = \#\{i \leq r : \sigma_i \geq \gamma\sigma_1\}$.	Giữ các chiều đạt ngưỡng so với giá trị kỳ dị lớn nhất. Steinberger & Ježek sử dụng $\gamma = 0,5$ [2]; phổ phẳng có thể khiến $k = r$.
Theo năng lượng tích lũy	$k = min\{q : E(q) \geq \theta\}$.	Chọn số chiều nhỏ nhất giữ được ít nhất tỷ lệ năng lượng θ, thường xét $0,8;\ 0,9;\ 0,95$.
Theo tập phát triển	Thử các ngưỡng γ hoặc θ, chọn theo tiêu chí như ROUGE-L F1.	Dùng cùng ngân sách tìm tham số giữa các biểu diễn và cố định cấu hình trước khi đánh giá trên tập kiểm tra.

Trong đó:

$$E(q) = \frac{\sum_{i=1}^{q} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}.$$

k quá nhỏ có thể bỏ mất thông tin cần thiết; k quá lớn làm giảm tác dụng lọc. Năng lượng giữ lại phản ánh mức xấp xỉ ma trận, không trực tiếp bảo đảm chất lượng tóm tắt.

2.5. Các cách chấm điểm và lựa chọn câu

Sau khi xác định k, tiến hành đánh giá câu và chọn c câu theo một trong hai phương pháp sau.

Tiêu chí	Gong & Liu (2001)	Steinberger & Ježek (2004)
Giá trị đánh giá	Tọa độ v_{ij} trên từng chiều. Báo cáo dùng biến thể $\lvert v_{ij} \rvert$ để loại phụ thuộc vào quy ước dấu.	Điểm tổng hợp $s_j = \sqrt{\sum_{i=1}^{k} \sigma_i^2 v_{ij}^2}$.
Cách chọn câu	Với mỗi chiều i, chọn câu có $\lvert v_{ij} \rvert$ lớn nhất, bỏ qua câu đã chọn.	Tính s_j cho tất cả câu, rồi chọn c câu có điểm cao nhất.
Quan hệ giữa k và c	$k = c$.	k độc lập với c.
Đóng góp trên nhiều chiều	Câu phải đứng đầu ở một chiều mới được chọn.	Câu có thể được chọn nhờ tổng đóng góp trên nhiều chiều.
Trọng số giá trị kỳ dị	Không sử dụng σ_i khi so sánh câu trên từng chiều.	Sử dụng σ_i làm trọng số.

Tiêu chí	Gong & Liu (2001)	Steinberger & Ježek (2004)
Hạn chế chính	Tăng số câu đồng nghĩa với sử dụng thêm các chiều yếu; có thể bỏ qua câu đóng góp tốt trên nhiều chiều.	Nếu $k = r$, điểm trở thành $\|a_j\|_2$; các cột đã chuẩn hóa L2 và khác 0 đều có điểm bằng 1.

Khi đồng điểm, ưu tiên câu xuất hiện trước theo quy tắc cố định. Với ma trận toàn 0, dùng phương án dự phòng theo vị trí. Sau khi chọn đủ c câu, sắp xếp chúng theo thứ tự trong văn bản gốc.

2.6. Mở rộng để giảm thiên lệch và trùng lặp

Giảm thiên lệch độ dài. Để hạn chế việc câu dài có điểm cao, có thể điều chỉnh:

$$s_j' = \frac{s_j}{\|a_j\|_2^{\alpha}}, \quad \alpha \in [0, 1]$$

Với $\alpha = 0$, điểm giữ nguyên; với $\alpha = 1$, điểm biểu thị tỷ lệ chuẩn hình chiếu so với chuẩn câu. Nếu $a_j = 0$, quy ước $s'_j = 0$. Cách này khác chuẩn hóa cột trước SVD, vì chuẩn hóa đầu vào còn làm thay đổi không gian kỳ dị.

Giảm trùng lặp. SVD không tự loại bỏ các câu giống nhau. Có thể dùng MMR [10] để lần lượt chọn câu vừa quan trọng, vừa ít trùng với các câu đã chọn:

$$MMR(j) = \lambda \hat{s}_j - (1 - \lambda) max_{\ell \in C} sim(j, \ell)$$

Trong đó, C là tập câu đã chọn; $\hat{s}_j$ là điểm đã đưa về thang đo phù hợp với độ tương đồng; $\lambda \in [0, 1]$ càng lớn càng ưu tiên mức quan trọng. Độ tương đồng có thể tính bằng cosine; khi C rỗng hoặc có vector 0, quy ước thành phần tương ứng bằng 0.

3. Các phương pháp đánh giá

Trong công thức ROUGE, $c_C(g)$ và $c_H(g)$ là số lần n-gram g xuất hiện trong bản tóm tắt ứng viên và bản tham chiếu.

Nhóm	Độ đo	Đo cái gì	Công thức	Lưu ý
Định lượng: chọn câu	Đồng chọn câu (P, R, F1)	Câu hệ thống chọn (C) trùng bao nhiêu với câu tham chiếu trích rút (H)	$P = \frac{\|C \cap H\|}{\|C\|}$ $R = \frac{\|C \cap H\|}{\|H\|}$ $F1 = \frac{2PR}{P+R}$	Đặt F1 = 0 nếu P + R = 0. Chỉ so chỉ số câu, nên cần thêm ROUGE khi các câu khác nhau có thể diễn đạt cùng ý

Nhóm	Độ đo	Đo cái gì	Công thức	Lưu ý
Định lượng: nội dung	ROUGE-1	Khớp từ đơn giữa ứng viên và tham chiếu	$M_n = \sum_g min\{c_C(g),\ c_H(g)\}$ $P_n = \frac{M_n}{\sum_g c_C(g)}$ $R_n = \frac{M_n}{\sum_g c_H(g)}$ $F1_n = \frac{2P_nR_n}{P_n+R_n}$ $n = 1$	Số khớp bị chặn bởi số lần xuất hiện ở mỗi phía. Cách xử lý n-gram rỗng và nhiều tham chiếu phải thống nhất theo công cụ
	ROUGE-2	Khớp cặp từ liên tiếp	Cùng công thức, n = 2	Như trên
	ROUGE-L	Độ dài dãy con chung dài nhất (LCS)	$P_L = \frac{L}{\|C\|}$ $R_L = \frac{L}{\|H\|}$ $F1_L = \frac{2P_LR_L}{P_L+R_L}$	Ghi rõ dùng ROUGE-L hay ROUGE-Lsum (xử lý ranh giới câu khác nhau)
Định tính	Đánh giá con người	Độ đầy đủ, dư thừa, mạch lạc	Chấm theo tiêu chí	Bổ sung cho ROUGE về khả năng đọc hiểu
Hiệu quả	Thời gian, bộ nhớ	Chi phí tính toán, khả năng triển khai	Đo thực tế	Phản ánh hiệu quả triển khai

3.1. Ví dụ tính ROUGE

Tham chiếu: "học_sinh sử_dụng trí_tuệ_nhân_tạo để học_tập hiệu_quả hơn" (7 token). Ứng viên: "học_sinh dùng trí_tuệ_nhân_tạo để học_tập hiệu_quả" (6 token).

Độ đo	Số khớp	Precision	Recall	F1
ROUGE-1	5	5/6 = 0,833	5/7 = 0,714	0,769
ROUGE-2	3	3/5 = 0,600	3/6 = 0,500	0,545
ROUGE-L	5	5/6 = 0,833	5/7 = 0,714	0,769

3.2. Giới hạn của ROUGE

"dùng" và "sử_dụng" gần nghĩa nhưng không khớp token, nên ROUGE bỏ sót. Với tiếng Việt, cần dùng cùng bộ tách token cho mọi hệ thống và công bố đơn vị chấm là từ hay âm tiết.